ANÁLISIS BIVARIADO SOBRE LIBERTADES EN ITALIA

Encuesta Social Europea, 2020/2022 (Ronda 10)

Técnicas de Investigación en Ciencia Política I. UBU Práctica 2.

Tomàs Ferrandis Moscardó

2024-05-19

Índice

1 INTRODUCCIÓN	3
1.1 DESCRIPCIÓN DE LA PRÁCTICA	
1.2 LIBRERÍAS R	
1.3 GESTIÓN DE FICHEROS DE DATOS	3
2 ACTIVIDAD 1. CONTRASTE DE MEDIAS PARA DATOS RELACIONADOS.	5
2.1 DESCRIPCIÓN DE LA ACTIVIDAD 1	
2.2 PREPARACIÓN DE LA BASE DE DATOS	5
2.3 HIPÓTESIS	
2.4 PRUEBA DE T-STUDENT	6
2.5 CONCLUSIÓN SOBRE T-STUDENT	7
3 ACTIVIDAD 2. ASOCIACIÓN DE VARIABLES.	8
3.1 DESCRIPCIÓN DE LA ACTIVIDAD 2	8
3.2 PREPARACIÓN DE LA BASE DE DATOS	8
3.3 HIPÓTESIS	9
3.4 LA TABLA DE CONTINGENCIA (TABLA CRUZADA)	9
3.5 CONCLUSIONES SOBRE LA TABLA DE CONTINGENCIA	
3.6 CÁLCULO DEL COEFICIENTE CHI CUADRADO	12
3.7 CONCLUSIÓN SOBRE CHI CUADRADO	13
4 ACTIVIDAD 3. RESPECTO A LA LIBERTAD DE LOS MEDIOS DE COMUNI-	
	14
4.1 DESCRIPCIÓN DE LA ACTIVIDAD 3	14
4.2 PREPARACIÓN DE LA BASE DE DATOS	14
4.3 HIPÓTESIS	
4.4 COEFICIENTE TAU-B DE KENDALL	
4.5 CONCLUSIÓN SOBRE TAU-B DE KENDALL	

4.6 COEFICIENTE DELTA (D) DE SOMERS	
5 VALORACIÓN CRÍTICA	17
6 EJECUCIÓN DEL Rmd Y REPOSITORIO DE FICHEROS	18

1 INTRODUCCIÓN

1.1 DESCRIPCIÓN DE LA PRÁCTICA

Este trabajo versará sobre las libertades en Italia a partir de diversos **análisis bivariados** sobre datos de la Encuesta Social Europea de los años 2020 y 2022 (Ronda 10). Se escogerá en cada caso el test más adecuado y, finalmente, se hará una valoración crítica a partir de los datos analizado. Las variables que se analizarán en las siguientes actividades corresponden al cuestionario de la encuesta

La práctica está relacionada con los temas 5 y 6 de la asignatura Técnicas de la Investigación en Ciencia Política I del Grado Universitario de Ciencia Política y Gestión Pública de la Universidad de Burgos, curso 2023-2024.

1.2 LIBRERÍAS R

Un primer paso será asegurar que en nuestra instalación de R están disponibles algunas funciones necesarias para abrir el fichero de datos externo (tipo .sav), para algún cálculo estadístico o formateo de datos en Rmd.

```
if(!require(haven)){install.packages("haven")} # para abrir fichero .sav
library(haven)
if(!require(knitr)){install.packages("knitr")} # Act. 2. Tabla Rd
library(knitr)
if(!require(DescTools)){install.packages("DescTools")} #actividad 3
library(DescTools)
```

1.3 GESTIÓN DE FICHEROS DE DATOS

Tanto el fichero de los datos de la encuesta (*datosprac2.sav*) como cualquier fichero de resultados se ubicarán en una subcarpeta DATOS del directorio donde se esté este mismo fichero Rmd.

```
# El fichero .sav debe estar en una subcarpeta DATOS
nombreFichero<-"datosprac2.sav"
directorioTrabajo<-getwd()</pre>
```

```
rutaFichero<-paste(directorioTrabajo, "DATOS", nombreFichero, sep="/")</pre>
```

A partir del fichero de tipo sav (datosprac2.sav) de la Encuesta Social Europea, se creará el *data frame* de R. Esta será la **base de datos** inicial con todos los datos de la encuesta.

```
df_ronda10<-read_sav(rutaFichero)</pre>
```

2 ACTIVIDAD 1. CONTRASTE DE MEDIAS PARA DATOS RELACIONADOS.

2.1 DESCRIPCIÓN DE LA ACTIVIDAD 1

En esta primera actividad se realizará un contraste de hipótesis para ver si dos variables presentan diferencias estadísticamente significativas entre si.

Las variables son:

- fairelcc: Las elecciones son libres y limpias en Italia (Pregunta B3 del cuestionario).
- cttresac: Los tribunales en Italia tratan a todo el mundo por igual (Pregunta B18 del cuestionario).

Ambas son Variables cualitativas ordinarias y admiten un valor que va desde 0 ("No es válida en absoluto") a 10 ("Es completamente válido") además de los valores considerados como no válidos a efectos estadísticos 77, 88 y 99 ("Rechaza responder", "NS No sabe" y "NC No contesta" respectivamente).

2.2 PREPARACIÓN DE LA BASE DE DATOS

Recodificación de valores no válidos

Se comprueba si hay valores que necesitan recodificarse. Serían los valores externos al intervalo [0-10] que según el codebook de la encuesta podrían ser 77, 88 ó 99 ya explicados.

unique(df ronda10\$fairelcc)

[1] 7 6 2 5 8 1 0 3 9 4 NA 10

unique(df ronda10\$cttresac)

[1] 1 0 2 8 3 7 6 5 9 4 NA 10

Se comprueba que ya deben estar recodificados o almenos no aparecen. No obstante, en caso de que no fuese así se procedería de la siguiente manera.

En primer lugar, se duplicarán los campos para hacer las modificación sobre estos.

```
df_ronda10$rec_cttresac <- df_ronda10$cttresac
df_ronda10$rec_fairelecc <-df_ronda10$fairelcc</pre>
```

Después, se recodifican los valores 77, 88 y 99 como NA

2.3 HIPÓTESIS

- Se plantea como hipótesis nula (H0) que ambas medias son iguales.
- La hipótesis alternativa (H1) sería, por lo tanto, que las medias son distintas.

2.4 PRUEBA DE T-STUDENT

Aplicaremos la función que implementa el método T-Student sobre los campos duplicados en nuestro caso.

- paired = T, indica a la función que operará con 2 muestras emparejadas.
- alternative = 'two.sized', indica que la hipótesis alternativa es que las medias no son iguales.
- Se establece un **nivel de confianza** del 95%.

```
## t = 22.183, df = 2503, p-value < 2.2e-16
## alternative hypothesis: true mean difference is not equal to 0
## 95 percent confidence interval:
## 1.110378 1.325724
## sample estimates:
## mean difference
## 1.218051</pre>
```

2.5 CONCLUSIÓN SOBRE T-STUDENT

A la vista del resultado de t_test , se comprueba que hay una diferencia significativa entre las medias de aproximadamente 1,22. El intervalo de confianza, con un nivel de confianza del 95%, es de 1.110378 a 1.325724. La probabilidad de errar por rechazar la hipótesis nula es prácticamente nula p=2.2x10e16; muy inferior al 0,05 que se establece habitualmente en ciencia política como límite para considerarlo un valor estadísticamente significativo.

Por lo que se debe rechazar la hipótesis nula que plantea la igualdad de las medias: las medias son distintas.

Esto se traduce en que existe una percepción distinta en los encuestados entre la libertad y limpieza del proceso electoral en Italia y el trato igualitario de su sistema judicial.

Dirección de la diferencia en la función de R

El valor positivo del estadístico *t-valor*, de los intervalos y de la *diferencia de medias* nos indica el orden de la diferencia. Viendo el orden de las variables en la función R, la primera variable "fairelecc" tiene una media en promedio mayor que la segunda "cttresac", por lo que la percepción de los encuestados sobre la limpieza de las elecciones es más postiva que la que tienen sobre la igualdad de trato del sistema judicial.

Si se invierte el orden de las variables en la función de R dará los mismos valores absolutos de *t*, de *intervalos* y de *diferencia de media* pero con signo negativo (cambiaría la dirección de la diferencia). El valor *p-value* seguirá igualmente positivo o absoluto puesto que indica la significancia estadística.

3 ACTIVIDAD 2. ASOCIACIÓN DE VARIABLES.

3.1 DESCRIPCIÓN DE LA ACTIVIDAD 2

En esta actividad se procederá a comprobar la asociación entre dos variables cualitativas ordinales.

Las variables a analizar serán:

- rec_hmsfmlsh, Me daría vergüenza que un familiar cercano fuese gay o lesbiana, representa la variable independiente y, por lo tanto, sus categorías corresponderán a filas en la tabla de contingencia (Pregunta A48 del cuestionario).
- rec_freehms, Los gays y lesbianas deberían tener libertad para vivir como quieran, representa la variable dependiente. Sus categorías corresponderán a columnas en la tabla (Pregunta A47 del cuestionario).

3.2 PREPARACIÓN DE LA BASE DE DATOS

Duplicación de campos

Se duplicarán las columnas del dataframe a manipular puesto que vamos a manipularlos.

```
df_ronda10$rec_hmsfmlsh<-df_ronda10$hmsfmlsh
df_ronda10$rec_freehms<-df_ronda10$freehms</pre>
```

Recodificación. Etiquetas de valores

Se añaden las etiquetas correspondientes a los valores en los campos tipo *factor* en los nuevos campos duplicados.

3.3 HIPÓTESIS

- Hipótesis nula: No hay asociación estadísticamente significativa entre las variables.
- Hipótesis alternativa: Hay asociación estadísticamente significativa entre las variables

3.4 LA TABLA DE CONTINGENCIA (TABLA CRUZADA)

Se obtienen los valores de frecuencia absolutos con la función *xtabs*.

```
freqtabla <- xtabs(~rec_hmsfmlsh + rec_freehms, data = df_ronda10)</pre>
```

Pero lo que interesa es tener en cada celda el % de casos respecto a la fila. Teniendo en cuenta que cada fila representa una categoría de la variable independiente. Se usará la función *prop.table*.

```
# El Parámetro 1 de prop.table indica % por fila
freqtabla_100xFila<-prop.table((freqtabla),1)*100</pre>
```

Se ve que la función no aporta los marginales (fila de totales). Para ello R dispone de otra función, *margin.table* :

```
Totales <- margin.table((prop.table(freqtabla)*100), 2)
```

Se combinan las dos matrices (*freqtabla_100xFila* y *Totales*) para elaborar la **Tabla de contingencia o Tabla cruzada** mediante la función *rbind*

```
tablaContingencia <- round(rbind(freqtabla_100xFila, Totales),2)
kable(tablaContingencia,
caption="Opinión sobre la libertad de gays y lesbianas (columnas)
```

según sentimiento de vergüenza por un familiar gay o lesbiana (filas)",
align=c("c","c","c","c","c"))

Tabla 1: Opinión sobre la libertad de gays y lesbianas (columnas) según sentimiento de vergüenza por un familiar gay o lesbiana (filas)

		De			
	Muy de	acuer-	Ni de acuerdo ni en	En des-	Muy en
	acuerdo	do	desacuerdo	acuerdo	desacuerdo
Muy de acuerdo	22.97	10.81	8.11	24.32	33.78
De acuerdo	4.07	36.65	25.79	26.24	7.24
Ni de acuerdo ni en	6.92	40.71	46.05	4.94	1.38
desacuerdo					
En desacuerdo	17.39	67.34	12.26	2.79	0.22
Muy en desacuerdo	66.87	28.80	1.69	0.60	2.05
Totales	30.54	45.02	16.61	5.18	2.65

3.5 CONCLUSIONES SOBRE LA TABLA DE CONTINGENCIA

En una primera observación sobre los **valores marginales** o totales se debe destacar que la mayoría de encuestados está "De acuerdo con las libertades de los gays y lesbianas" (45.02%) siendo la segunda opción "Muy de acuerdo" (30,54%), además la respuesta con menor porcentaje es la de "Muy en desacuerdo" (2,65%).

Al observar los valores de las diferentes **categorías de la variable independiente** o filas se tiene un primer bloque con las dos categorías de encuestados que reconocen que sentirían algún tipo de vergüenza por tener un familiar homosexual. Aquí se ve una diferencia notable entre ambas categorías:

• Por un parte los que responden estar "Muy de acuerdo" con este sentimiento de vergüenza, su posicionamiento mayoritario es contrario a la libertad, decantándose un 33,78% por "Muy en desacuerdo" y un 24,32% por "En desacuerdo". No obstante aparece un dato muy interesante: un importante 22,97% que se manifiesta "Muy de acuerdo" con la libertad.

• Por otra parte, los que se muestran "De acuerdo" con la afirmación de vergüenza, su posición mayoritaria respecto a la libertad es estar "De acuerdo" (36,65%), un dato también interesante. Seguidamente optan por "En desacuerdo" y "Ni de acuerdo ni en desacuerdo" con cifras similares (26,24% y 25,79% respectivamente).

Un nivel intermedio lo configuraría la categoría más "neutral": los que no están "Ni de acuerdo ni en desacuerdo" con sentir vergüenza y que también se decantan mayoritariamente por la misma posición neutra, ocupando el centro de la tabla, con un 46,05%. Valores muy alejados del 4,94 o 1,38 de oposición a las libertades. Aunque es importante señalar que su segunda opción es posicionarse "De acuerdo" con las libertades de gays y lesbianas (40,71%), se ve una relación "Ni de acuerdo ni en desacuerdo- Ni desacuerdo ni desacuerdo"

En un tercer bloque estarían las dos categorías que manifiestan rechazo a la idea de sentir vergüenza por tener un familiar homosexual. Aquí también se ven unas relaciones con cierta lógica.

- Los encuestados que están "En desacuerdo", son los que más se posicionan mayoritariamente también como "De acuerdo" con las libertades (67,34%).
- Con cifras similares, en el extremo, los que están "Muy en desacuerdo" con la afirmación sobre avergonzarse se declaran "Muy de acuerdo con la libertad" (66,84%).

En resumen, entre los que no sentirían vergüenza por tener un familiar homosexual se ve una coincidencia "De acuerdo-desacuerdo" y "Muy desacuerdo-muy de acuerdo" en lo que respeta a las libertades de este colectivo.

Cuando se examina columna a columna toda la tabla, se observa que los valores de cada columna varían respecto a su correspondiente valor marginal. De hecho no se observa ninguna coincidencia lo que nos lleva a concluir una dependencia entre las variables.

3.6 CÁLCULO DEL COEFICIENTE CHI CUADRADO

Este coeficiente se muestra junto a las tablas cruzadas y nos indica si existe asociación entre la variable independiente (filas) y la dependiente (columnas). Solo arroja un valor igual o mayor que cero.

- Si vale 0 significa que no hay asociación.
- Si es >0, existe asociación, cuanto mayor sea, más evidencia hay.
- Al dar siempre valores positivos (absolutos), no indica ninguna dirección de la asociación.

En R existe la función *chisq* para el cálculo de *Chi cuadrado* con dos parametrizaciones posibles.

• Pasando como argumentos directamente las variables a la función *chisq.test*

```
chi <- chisq.test( df ronda10$rec hmsfmlsh, df ronda10$rec freehms)</pre>
## Warning in chisq.test(df ronda10$rec hmsfmlsh, df ronda10$rec freehms):
## L'aproximació Chi-quadrat pot ser incorrecta
chi
##
    Pearson's Chi-squared test
##
##
## data: df_ronda10$rec_hmsfmlsh and df_ronda10$rec_freehms
## X-squared = 1723.8, df = 16, p-value < 2.2e-16
   • Pasando como argumento la tabla en chisq.test
chi <- chisq.test(freqtabla)</pre>
## Warning in chisq.test(freqtabla): L'aproximació Chi-quadrat pot ser incorrecta
chi
##
    Pearson's Chi-squared test
##
## data:
          freqtabla
## X-squared = 1723.8, df = 16, p-value < 2.2e-16
```

3.7 CONCLUSIÓN SOBRE CHI CUADRADO

El coeficiente indica la magnitud de la asociación. El valor de 1723,8 es muy superior a 0, lo que indica una asociación fuerte. Hay una evidencia para el rechazo de la H0 (independencia de las variables) y además, el *p-valor* es muy inferior (2.2x10e16) a *alpha* (0,001) por lo que hay un nivel de confianza superior al 99,9%.

Se debe rechazar la hipótesis nula: las variables están asociadas.

4 ACTIVIDAD 3. RESPECTO A LA LIBERTAD DE LOS MEDIOS DE COMUNICACIÓN

4.1 DESCRIPCIÓN DE LA ACTIVIDAD 3

En esta actividad se pretende analizar si existe una dependencia entre la autoubicación ideológica de los encuestados y su percepción sobre el nivel de crítica que ejercen los medios de comunicación respecto al gobierno italiano.

Para ello se analizarán las variables:

- Irscale, ¿Dónde se colocaría usted en la escala? Escala de 0 a 10 (0 representa la ubicación más a la izquierda y 10 la ubicación más a la derecha). Esta es la variable independiente (Pregunta A39 del cuestionario)
- medcrgvc, Los medios de comunicación en Italia pueden criticar al gobierno. Escala de 0 a 10 (0 indica No es válida en absolutao y 10, Es complettamente válida). Esta es la variable dependiente (Pregunta B15 del cuestionario)

4.2 PREPARACIÓN DE LA BASE DE DATOS

Se comprueba que no hay valores que recodificar como NA

unique(df_ronda10\$lrscale)
[1] NA 5 8 6 4 3 10 1 2 7 9 0
unique(df_ronda10\$medcrgvc)

[1] 1 3 6 5 8 10 2 0 9 7 4 NA

Si fuese necesario recodificar por cualquier motivo (valores no válidos, añadir etiquetas...) que no es este el caso, convendría hacerlo sobre una duplicación de estos campos de forma análoga a lo realizado a apartados 2.2 de las dos actividades anteriores.

4.3 HIPÓTESIS

 H0, hipótesis nula: No hay asociación estadísticamente significativa entre las variables. H1, hipótesis alternativa: Hay asociación estadísticamente significativa entre las variables.

4.4 COEFICIENTE TAU-B DE KENDALL

Se trata del test más adecuado para analizar dos variables cualitativas ordinales que tienen el mismo número de categorías como es este caso. Este coeficiente nos indica si hay asociación entre dos variables y la dirección de esta. Sus valores oscilan entre -1 y 1, siendo el 0 el valor resultante cuando no existe asociación. El signo nos indica la dirección de la asociacion: valor negativo si una variable aumenta mientras la otra disminuye y valor positivo si ambas aumentan o disminuyen a la vez.

```
## tau_b lwr.ci upr.ci
## -0.009130106 -0.043788752 0.025528540
```

El coeficiente *tau_b* (-0.009130106) es negativo y cercano a 0 Los valores *lwr.ci* y *upr.ci* (-0.043788752 0.025528540 respectivamente) son los límites inferior y superior del intervalo de confianza del 95%.

4.5 CONCLUSIÓN SOBRE TAU-B DE KENDALL

Sobre el coeficiente: El coeficiente, al ser negativo, indicaría que cuando aumenta una variable la otra disminuye (dirección de la asociación) pero al tratarse de un valor tan cercano a 0 (-0.009130106) nos sugiere que no hay asociación estadísticamente relevante entre las variables.

Sobre el intervalo de confianza: Los valores de *lwr.ci* y *upr.ci* indican que, con un 95% de confianza, el verdadero valor del coeficiente de Kendall se encuentra dentro de él. Este intervalo incluye al 0 (-0.043788752 <0< 0.025528540) hecho que refuerza la interpretación de que no hay una asociación estadísticamente significativa entre las variables.

Por todo esto:

NO se puede rechazar la hipótesis nula y consecuentemente no hay asociación estadística

entre las variables

4.6 COEFICIENTE DELTA (D) DE SOMERS.

Se trata de otro test de asociación para variables cualitativas ordinales que también nos informa de la magnitud y la dirección de la asociación mediante un coeficiente. Sus valores y la interpretación de estos es idéntica al Tau-B de Kendall: intervalo de -1 a 1, valor 0 para indicar la inexistencia de asociación y el signo para la dirección.

```
## somers lwr.ci upr.ci
## -0.009052743 -0.043415457 0.025309971
```

El coeficiente de *Somers* (-0,009052743) cercano a 0 y negativo.

Los valores *lwr.ci* y *upr.ci* (-0.043415457 y 0.025309971) son los límites inferior y superior del intervalo de confianza del 95%.

4.7 CONCLUSIÓN SOBRE DELTA (D) DE SOMERS

Sobre le coeficiente: Aunque el coeficiente, al ser negativo indica que cuando aumenta una variable la otra disminuye (dirección de la asociación), al tratarse de un valor tan cercano a 0 (-0.009052743) este sugiere que no hay asociación estadísticamente relevante entre las variables.

Sobre el intervalo de confianza: Los valores de *lwr.ci* y *upr.ci* indican que, con un 95% de confianza, el verdadero valor del coeficiente de Sommers se encuentra dentro de él. Este intervalo incluye al 0 (-0.043415457 <0 <0.025309971) hecho que refuerza la interpretación de que no hay una asociación estadísticamente significativa entre las variables.

Por todo esto:

NO se puede rechazar la hipótesis nula por lo tanto NO hay asociación estadística entre las variables

Se comprueba que ambos coeficientes nos llevan a la misma conclusión.

5 VALORACIÓN CRÍTICA

Las libertades analizadas están operacionalizadas como variables ordinales pero pueden ser tratadas individualmente como cuantitativas para obtener más información como se estudió en la práctica anterior. Así se puede ver que los italianos encuestados "aprueban" su sistema electoral con un 5,8 de media y una mediana de 6 mientras que suspenderían a sus tribunales por trato desigual (media de 4,52 y apenas una mediana de 5). Considerando que se compara la confianza en un proceso de máxima participación y reglamentación con la práctica diaria de órganos de funcionarios y que Italia es una democracia consolidada esta poca confianza en la limpieza y libertad de las elecciones es un hecho preocupante.

Los encuestados mayoritariamente no se identifican con el sentimiento de vergüenza por tener un familiar homosexual (media de 3,8 y mediana de 4 en un intervalo de 1 a 5). Un sentimiento relacionado, como se ha visto, con su posicionamiento favorable a la igualdad de libertades de este colectivo (una media de 2,05 y una mediana de 2 en un intervalo de 1 a 5). Ambas medidas distan un punto, aproximadamente, del extremo que definiría un sentimiento y posición más tolerante o progresista. Sería interesante un seguimiento de las rondas siguientes para ver la evolución.

Con bastante independencia de la ideología, los encuestados aprueban la independencia respecto del gobierno de sus medios de comunicación. Al observar la distribución de valores, tenemos que destacan los valores de 6 a 8 (entre 0 y 10). En una valoración bastante positiva tratándose de un modelo de prensa latino.

6 EJECUCIÓN DEL Rmd Y REPOSITORIO DE FICHEROS

Para la ejecución del código R, está disponible el fichero ejecutable Rmd y el fichero de datos *sav* en el repositorio GitHub. En el mismo repositorio se encuentra este PDF y un fichero HTML renderizados a partir del Rmd.

El fichero **datosprac2.sav** debe ubicarse en una subcarpeta del directorio de trabajo con nombre *DATA*.

P		Enlace a GitHub
SAV	Fichero de datos tipo sav	datosprac2.sav
rmarkdown	Fichero Rmd	libertadesItalia2022.Rmd
HTML	Fichero HTML	libertadesItalia2022.html
<u> </u>	Fichero PDF	libertadesItalia.pdf
GitHub		Repositorio tofermos